



Facultad de
Economía y Empresa



UNIVERSIDAD CATÓLICA
DE SANTIAGO DE GUAYAQUIL



Carrera de
Administración
de Empresas

UNIVERSIDAD CATÓLICA DE SANTIAGO DE GUAYAQUIL

FACULTAD DE ECONOMÍA Y EMPRESA

CARRERA DE ADMINISTRACIÓN DE EMPRESAS

BIG DATA

TÍTULO:

Comparación de Modelos en el Dataset Titanic

INTEGRANTES:

Arias Patiño Amy Romina

Calvopiña Hernandez Esteban

Delgado Monge Eduardo José

Parrales Calderón Mirian Estefanía

VII CICLO

DOCENTE:

Ing. Xavier Jácome Piñeiros, MSc.

SEMESTRE A-2026

Informe: Comparación de Modelos en el Dataset Titanic

1. Introducción

El presente proyecto tiene como objetivo predecir la supervivencia de los pasajeros del Titanic mediante técnicas de machine learning. La variable objetivo es Survived, donde 1 representa que el pasajero sobrevivió y 0 que no sobrevivió.

El dataset contiene 891 registros y variables como edad, sexo, clase del pasajero, tarifa pagada, número de familiares a bordo y puerto de embarque. Durante el análisis inicial se identificaron valores faltantes en variables como Age, Cabin y Embarked, por lo que fue necesario aplicar técnicas de imputación.

El trabajo va más allá de un modelo básico porque se desarrolló un pipeline completo que incluye limpieza de datos, transformación de variables, creación de nuevas características, comparación de cuatro modelos, optimización de hiperparámetros y análisis de overfitting.

2. Feature engineering aplicado

Se aplicó ingeniería de características para mejorar la calidad de los datos y aumentar la capacidad predictiva de los modelos. Las variables creadas fueron:

- FamilySize: representa el tamaño total de la familia del pasajero a bordo.
- Is_alone: identifica si el pasajero viajaba solo o acompañado.
- Fare_per_person: calcula la tarifa pagada por persona.
- Deck: se obtiene a partir de la cabina y permite aproximar la ubicación del pasajero en el barco.

- Title: se extrae del nombre del pasajero, por ejemplo Mr, Mrs, Miss o Master.
- Age_Pclass: combina la edad del pasajero con su clase social.

Estas variables son importantes porque reflejan factores sociales, económicos y familiares que pudieron influir en la probabilidad de supervivencia.

3. Resultados

Se evaluaron cuatro modelos:

1. Decision Tree
2. Random Forest Optimizado
3. Gradient Boosting Optimizado
4. Logistic Regression

Los modelos Random Forest y Gradient Boosting fueron optimizados con GridSearchCV y validación cruzada de 5 particiones.

Tabla comparativa de resultados

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	AUC-ROC
Logistic Regression	0.8380	0.8323	0.8223	0.8265	0.8682
Random Forest Optimizado	0.8101	0.8066	0.7860	0.7933	0.8528
Gradient Boosting Optimizado	0.7933	0.7837	0.7751	0.7787	0.8372

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	AUC-ROC
Decision Tree	0.7765	0.7645	0.7615	0.7629	0.7466

El modelo con mejor desempeño fue Logistic Regression, ya que obtuvo los valores más altos en Accuracy, F1 macro y AUC-ROC. Esto demuestra que fue el modelo más equilibrado para clasificar correctamente a los pasajeros que sobrevivieron y los que no sobrevivieron.

Análisis de overfitting

Modelo	Train F1 macro	CV F1 macro	Diferencia
Decision Tree	0.9866	0.7479	0.2387
Random Forest Optimizado	0.9078	0.8165	0.0913
Gradient Boosting Optimizado	0.9083	0.8175	0.0907
Logistic Regression	0.8297	0.8091	0.0206

El modelo con mayor overfitting fue Decision Tree, porque tuvo un resultado muy alto en entrenamiento, pero bajó bastante en validación cruzada. En cambio, Logistic Regression presentó la menor diferencia entre entrenamiento y validación, lo que indica que generaliza mejor.

Interpretación de gráficos

La matriz de confusión del mejor modelo permitió observar los aciertos y errores al clasificar pasajeros sobrevivientes y no sobrevivientes. La curva ROC mostró que Logistic Regression tuvo la mejor capacidad de separación entre clases, con un AUC-ROC de 0.8682.

Además, el análisis de importancia de variables mostró que las características más influyentes fueron Name, Sex, Age, Pclass y SibSp. Esto tiene sentido porque el sexo, la edad, la clase social y el grupo familiar fueron factores importantes en la supervivencia durante el desastre del Titanic.

4. Conclusiones

El modelo recomendado es Logistic Regression, porque obtuvo el mejor rendimiento general y presentó menor riesgo de overfitting. Su F1 macro de 0.8265 y su AUC-ROC de 0.8682 indican que logró un buen equilibrio entre precisión, recall y capacidad de clasificación.

Aunque Random Forest y Gradient Boosting también tuvieron resultados aceptables, no superaron a la regresión logística. Además, estos modelos mostraron una mayor diferencia entre entrenamiento y validación, lo que indica un mayor riesgo de sobreajuste.

Entre las limitaciones del análisis se encuentra el tamaño reducido del dataset y la existencia de valores faltantes, especialmente en variables como Age y Cabin. También se utilizó una sola división entre entrenamiento y prueba, por lo que los resultados podrían variar con otra partición.

Si se tuviera más tiempo, se podrían probar nuevas variables, aplicar técnicas más avanzadas de imputación, usar validación cruzada más robusta y analizar el modelo con herramientas de interpretabilidad como SHAP.

En conclusión, el proyecto demuestra que un pipeline bien construido, junto con ingeniería de variables y comparación de modelos, permite obtener resultados sólidos. Por sus métricas y estabilidad, Logistic Regression es el modelo más recomendable para este caso.